

Universidad Torcuato Di Tella
Maestría en Economía
Econometría de series de tiempo
Exámen 2023

Oscar Jaramillo

Sección 1

Para todos los ejercicios existe un archivo de eviews donde se pueden encontrar las estimaciones, gráficos, tablas, pruebas y demás recursos utilizados para resolver los problemas, se utilizaron además dos add-ins de Eviews, Local Projections IRF'S que permite calcular funciones impulso respuesta a través de proyecciones locales y bayeslinear que permite estimar modelos a través de técnicas de cadenas de Markov Montecarlo MCMC.

1. Use the Eviews data file named Findata.wf1


Consider the series retgoog

- a) Find the ARMA(p,q) that characterizes the series. Test whether the series has ARCH effects.

Solución

Vamos a aplicar la metodología de Box Jenkins para identificar el modelo que representa la serie, queremos comprobar si la serie es estacionaria, empezamos graficando la serie para poder observar su comportamiento en el tiempo.

Figura 1: retgoog



De forma preliminar podemos ver en la figura 1 que la serie retgoog no tiene una tendencia aparente, sino que parece oscilar de forma aleatoria alrededor de cero por lo que parece ser estacionaria

Cuadro 1: retgoog ADF test

Valores críticos	estadístico t	Prob
1 %	-3.443228	
5 %	-2.867112	
10 %	-2.569800	
ADF test	-17.89954	0.0000

El cuadro 1 muestra el test Augmented Dickey-Fuller que nos permite rechazar la hipótesis nula de que la serie tiene una raíz unitaria lo que indica que la serie es estacionaria por lo que graficar el correlograma no nos dará información adicional. Así que directamente estimamos algunos modelos:

Cuadro 2: retgoog ARMA(3,3)

Variable	Coeficiente	Error estándar	Estadístico t	Valor p
AR(1)	-0.143705	0.144241	-0.996282	0.3196
AR(2)	-0.124339	0.112602	-1.104236	0.2700
AR(3)	0.723346	0.123173	5.872583	0.0000
MA(1)	0.147622	0.131247	1.124763	0.2612
MA(2)	0.002443	0.104523	0.023371	0.9814
MA(3)	-0.780849	0.105205	-7.422161	0.0000
σ^2	2.614107	0.094807	27.57301	0.0000
Akaike info criterion			3.827387	
Schwarz criterion			3.886302	
Hannan-Quinn criterion			3.850503	

Aquí podemos empezar a ver que las estimaciones empiezan a no ser estadísticamente relevantes, hacemos algunas estimaciones para ajustar un poco

Cuadro 3: retgoog ARMA(1 to 3,3)

Variable	Coeficiente	Error estándar	Estadístico t	Valor p
AR(1)	-9.84E-05	0.028257	-0.003481	0.9972
AR(2)	-0.129181	0.036250	-3.563610	0.0004
AR(3)	0.736229	0.102030	7.215780	0.0000
MA(3)	-0.746272	0.105516	-7.072582	0.0000
Akaike info criterion			3.821800	
Schwarz criterion			3.863882	
Hannan-Quinn criterion			3.838311	

Podemos quitar el AR(1)

Cuadro 4: retgoog, ARMA(2 to 3,3)

Variable	Coeficiente	Error estándar	Estadístico t	Valor p
AR(2)	-0.129155	0.035712	-3.616516	0.0003
AR(3)	0.736282	0.100419	7.332095	0.0000
MA(3)	-0.746296	0.104750	-7.124517	0.0000
σ^2	2.620915	0.094942	27.60550	0.0000
Akaike info criterion			3.817808	
Schwarz criterion			3.851473	
Hannan-Quinn criterion			3.831017	

Con esta especificación minimizamos también los tres criterios de información, se hicieron varias corridas con la constante y con AR o MA cercanos pero la significatividad y los residuos se veían afectados, por lo que nos quedamos con este modelo que además parece ser representativo a nivel conjunto, lo que podemos ver con un test de Wald bajo la hipótesis nula $H_0 : AR(2) = AR(3) = MA(3) = 0$ esto nos lleva a descartar multicolinealidad con esta expresión.

Cuadro 5: retgoog Test Wald, significatividad conjunta

Test Statistic	Value	df	Probability
F-statistic	50.05325	(3, 497)	0.0000
Chi-square	150.1597	3	0.0000

Figura 2: Correlograma retgoog

Autocorrelation	Partial Correlation	AC	PAC	Q-Stat	Prob
		1	-0.011	-0.011	0.0663
		2	0.013	0.013	0.1580
		3	0.022	0.023	0.4107
		4	-0.025	-0.025	0.7286
		5	0.026	0.025	1.0710
		6	-0.082	-0.081	4.4612
		7	0.049	0.048	5.6720
		8	-0.027	-0.027	6.0535
		9	0.015	0.019	6.1666
		10	0.012	0.006	6.2408
		11	-0.101	-0.095	11.490
		12	0.011	-0.001	11.549
		13	0.003	0.015	11.554
		14	0.006	0.004	11.573
		15	0.021	0.021	11.797
		16	0.046	0.050	12.883
		17	0.073	0.059	15.666
		18	0.068	0.079	18.092
		19	-0.045	-0.052	19.132
		20	-0.081	-0.085	22.609
		21	-0.024	-0.024	22.922
		22	-0.030	-0.032	23.396
		23	0.093	0.104	27.981
		24	-0.015	-0.003	28.102
		25	0.068	0.061	30.532
		26	0.072	0.068	33.254
		27	-0.029	-0.019	33.707
		28	0.018	0.014	33.888
		29	-0.079	-0.054	37.244
		30	0.011	-0.016	37.310
		31	-0.011	-0.017	37.372
		32	0.041	0.042	38.268
		33	0.122	0.110	46.263
		34	-0.062	-0.038	48.306
		35	-0.020	-0.050	48.531
		36	0.019	0.042	48.721

Si analizamos el correlograma de este modelo vemos que en general la estructura se limpia, sin embargo a partir del lag 26 la representatividad de los residuos empieza a oscilar y a perderse al 10 % de significatividad a partir del lag 33 la significatividad se pierde al 5 %, después de algunas pruebas, aunque se alcanza significatividad con un AR(29) y un MA(29) los residuos presentan estructura, por lo que el modelo podría dejarse como un ARMA(2,3).

Cuadro 6: retgoog Heteroskedasticity Test: ARCH

Variable	Coefficient	Std. Error	t-Statistic
F-statistic	0.409831	Prob. F(1,498)	0.5223
Obs*R-squared	0.411139	Prob. Chi-Square(1)	0.5214

Si consideramos el test de heterocedasticidad para efectos ARCH, vemos que no se puede rechazar la hipótesis nula de ausencia de heterocedasticidad, por lo que tenemos razones para creer que no existen efectos ARCH en esta especificación, esto sin embargo se puede deber a que estamos utilizando el modelo ARMA(2 to 3, 3) de la serie.

- b) Estimate an ARCH(1) and comment on the results. Plot the conditional variances of the estimated model.

Cuadro 7: retgoog ARMA(2 to 3, 3)

Variable	Coefficient	Std. Error	t-Statistic	Prob.
AR(2)	-0.129155	0.035712	-3.616516	0.0003
AR(3)	0.736282	0.100419	7.332095	0.0000
MA(3)	-0.746296	0.104750	-7.124517	0.0000
σ^2	2.620915	0.094942	27.60550	0.0000
R-squared	0.038319	Mean dependent var		0.045271
Adjusted R-squared	0.032514	S.D. dependent var		1.652513
S.E. of regression	1.625426	Akaike info criterion		3.817808
Sum squared resid	1313.078	Schwarz criterion		3.851473
Log likelihood	-952.3608	Hannan-Quinn criterion		3.831017
Durbin-Watson stat	2.016586			
Inverted AR Roots	0.86	-0.43 - 0.82i		-0.43 + 0.82i
Inverted MA Roots	0.91	-0.45 - 0.79i		-0.45 + 0.79i

Cuadro 8: retgoog ARCH(1) model

Variable	Coefficient	Std. Error	z-Statistic	Prob.
AR(2)	-0.132066	0.035237	-3.747893	0.0002
AR(3)	0.736145	0.094023	7.829371	0.0000
MA(3)	-0.756285	0.098224	-7.699592	0.0000
Variance Equation				
C	2.396145	0.099040	24.19380	0.0000
RESID(-1) ²	0.095712	0.042053	2.275995	0.0228
R-squared	0.039748	Mean dependent var		0.038644
Adjusted R-squared	0.035869	S.D. dependent var		1.654704
S.E. of regression	1.624757	Akaike info criterion		3.815322
Sum squared resid	1306.719	Schwarz criterion		3.857597
Log likelihood	-945.0153	Hannan-Quinn criterion		3.831914
Durbin-Watson stat	2.022452			
Inverted AR Roots	0.85	-0.43 - 0.82i		-0.43 + 0.82i
Inverted MA Roots	0.91	-0.46 - 0.79i		-0.46 + 0.79i

Los cuadros 7 y 8 presentan el modelo ARMA para retgoog y el modelo ARCH(1) respectivamente, vemos que los coeficientes en ambos modelos son prácticamente los mismos, la representatividad se mantiene y si observamos la ecuación de la varianza del modelo ARCH(1) vemos que la inclusión de un lag de la variable es significativa al 95 % lo que significa que de esta manera podemos estar limpiando los efectos que tiene la varianza es decir la volatilidad de retgoog.


Vimos en el punto anterior que una prueba de heterocedasticidad nos hacía descartar la presencia de efectos ARCH, pero al calcular el modelo ARCH(1) encontramos significatividad, esto se puede deber a un outlier de volatilidad que no se mantiene durante el tiempo suficiente como para ser encontrada en el test conjunto de toda la muestra pero que si tiene un efecto significativo y puede ser modelado a través de un ARCH(1).

Figura 3: Correlograma de residuos al cuadrado retgoog

Autocorrelation	Partial Correlation	AC	PAC	Q-Stat	Prob*
		1 -0.016	-0.016	0.1331	0.715
		2 0.011	0.010	0.1896	0.910
		3 0.027	0.028	0.5696	0.903
		4 0.007	0.008	0.5960	0.964
		5 -0.012	-0.013	0.6726	0.984
		6 0.104	0.103	6.1659	0.405
		7 -0.034	-0.031	6.7538	0.455
		8 -0.021	-0.024	6.9855	0.538
		9 0.012	0.007	7.0556	0.631
		10 0.009	0.010	7.0963	0.716
		11 -0.005	-0.001	7.1089	0.790
		12 0.032	0.020	7.6357	0.813
		13 0.031	0.038	8.1248	0.835
		14 0.052	0.057	9.5008	0.798
		15 -0.013	-0.017	9.5819	0.845
		16 -0.013	-0.019	9.6700	0.883
		17 -0.015	-0.016	9.7795	0.913
		18 0.048	0.044	10.965	0.896
		19 -0.023	-0.025	11.231	0.916
		20 0.062	0.054	13.221	0.868
		21 -0.032	-0.025	13.770	0.879
		22 0.010	0.012	13.818	0.908
		23 0.079	0.080	17.120	0.803
		24 0.037	0.028	17.851	0.810
		25 -0.016	-0.011	17.993	0.843
		26 -0.008	-0.029	18.029	0.875
		27 -0.008	-0.005	18.059	0.902
		28 0.025	0.026	18.388	0.916
		29 -0.029	-0.041	18.822	0.926
		30 -0.011	-0.014	18.890	0.942
		31 -0.042	-0.035	19.837	0.939
		32 0.021	0.019	20.063	0.950
		33 -0.016	-0.016	20.208	0.960
		34 0.009	-0.000	20.252	0.970
		35 -0.003	0.006	20.258	0.978
		36 -0.000	-0.009	20.258	0.984

Esto también lo podemos ver en el correlograma de los residuos al cuadrado del modelo ARCH(1) que es capaz de limpiar de estructura a la volatilidad de la variable.

Figura 4: retgoog



Finalmente en la figura 4 vemos el gráfico de la varianza condicional del modelo, nótese que en el 2019 segundo y tercer trimestre existen puntos muy altos de varianza en com-

paración con el resto de la serie, pero luego regresan e incluso parecen alcanzar mínimos durante el cuarto trimestre.

- c) Do you think the results on (a) and (b) are consistent? And, if not, to what could you attribute the difference?

Los resultados parecen ser contradictorios, ya que en (a) la prueba de heterocedasticidad para efectos ARCH arroja ausencia de este tipo de efectos, pero en (b) si estimamos un modelo ARCH(1) vemos que existen efectos ARCH significativos al 95 %, esto se debe sin embargo a que no hay un quiebre estructural, es decir la varianza sigue un modelo que durante el periodo analizado no cambia, sin embargo existen outliers en la varianza que una prueba de heterocedasticidad conjunta no es capaz de capturar pero que si aparece como significativa en un modelo ARCH(1).

Depende el objetivo del análisis utilizar el modelo ARCH si se quiere capturar el efecto de esos outliers en la volatilidad o no, si bien los resultados parecen contradictorios, son consistentes si los miramos juntos.

2. Use the Eviews data file named Findata.wfl

Consider the variables retgoog, retko and retmcd

- a) Find the order of a VAR(p) which contains those variables.

Solución

Tomando las variables retgoog, retko y retmcd para un VAR podemos empezar buscando si las variables son estacionarias o si podríamos considerar diferenciar alguna, por supuesto existe la posibilidad que variables no estacionarias juntas en un VAR no traigan problemas.

Cuadro 9: retgoog ADF test

Valores críticos	estadístico t	Prob
1 %	-3.443228	
5 %	-2.867112	
10 %	-2.569800	
ADF test	-17.89954	0.0000

Cuadro 10: retko ADF test

Valores críticos	estadístico t	Prob
1 %	-3.443228	
5 %	-2.867112	
10 %	-2.569800	
ADF test	-17.71654	0.0000

Cuadro 11: retmcd ADF test

Valores críticos	estadístico t	Prob
1 %	-3.443202	
5 %	-2.867101	
10 %	-2.569793	
ADF test	-23.36775	0.0000

Los cuadros 9, 10 y 11 muestran que las tres variables parecen ser estacionarias según el test Dickey-Fuller, esto también se debe a que las tres variables son transformaciones lineales de una transformación logarítmica de las variables goog, ko y mcd en niveles.

Para elegir el orden del VAR es necesario elegir algún criterio:

Cuadro 12: Model Selection Criteria

Lag	LogL	LR	FPE	AIC	SC	HQ
0	-2380.610	NA	3.177791*	9.669817*	9.695378*	9.679854*
1	-2374.971	11.18742	3.221414	9.683450	9.785694	9.723595
2	-2366.293	17.10963*	3.225639	9.684757	9.863683	9.755009
3	-2359.244	13.81116	3.251312	9.692673	9.948282	9.793034
4	-2355.361	7.561207	3.319577	9.713432	10.04572	9.843901
5	-2349.364	11.60498	3.360370	9.725614	10.13459	9.886191
6	-2342.080	14.00663	3.384001	9.732575	10.21823	9.923261
7	-2340.308	3.385558	3.484920	9.761898	10.32424	9.982692
8	-2336.083	8.021307	3.553383	9.781270	10.42029	10.03217

En el cuadro 12 tenemos algunos criterios de selección para elegir el orden del modelo VAR, la elección del VAR también debe considerar el uso que se dará al modelo, si el objetivo es encontrar el orden correcto del proceso generador de los datos es mejor utilizar el estadístico del test del ratio de verosimilitud (Likelihood Ratio test statistic) o LR test mientras que si el objetivo es la predicción puede ser mejor utilizar los criterios de información FPE (final prediction error), AIC (Akaike information criterion), SC (Schwarz information criterion) o HQ (Hannan-Quinn information criterion).

Hay que considerar que si el objetivo es encontrar el proceso generado de los datos, existe la posibilidad que un criterio de información nos lleve a elegir un orden incorrecto incluso si el tamaño de la muestra es grande (Lütkepohl 2005).

Además del objetivo del análisis, utilizar un criterio de información u otro también puede depender del tamaño de la muestra, en nuestro caso tenemos 502 observaciones de datos diarios irregulares, es decir, que no están disponibles para todos los periodos de forma exhaustiva. Con muestras grandes AIC y FPE eligen el orden correcto casi con probabilidad 1 (Lütkepohl 2005), mientras que SC y HQ eligen el orden correcto si la dimensión del proceso es mayor a 1.

Considerando estos aspectos estimamos VAR(2) y VAR(0)

Cuadro 13: Chi-squared Test Statistics for Lag Exclusion VAR(1 2)

	RETGOOG	RETKO	RETMCD	Joint
Lag 1	2.512614 [0.4730]	2.079347 [0.5561]	4.887115 [0.1803]	10.28228 [0.3281]
Lag 2	6.975424 [0.0727]	9.821711 [0.0201]	4.012654 [0.2601]	17.32773 [0.0438]
df	3	3	3	9

Los resultados del cuadro 13 muestran un test de significatividad para los lag incluidos en el modelo, estos resultados nos permiten excluir el lag 1 debido a que no es representativo para ninguna variable y tampoco de forma conjunta.

Cuadro 14: Chi-squared Test Statistics for Lag Exclusion VAR(2 2)

	RETGOOG	RETKO	RETMCD	Joint
Lag 2	7.401491 [0.0601]	10.40661 [0.0154]	4.207097 [0.2400]	18.39664 [0.0308]
df	3	3	3	9

Vemos que en el caso de la variable retmcd, un lag2 no es significativo, sin embargo si es significativo de forma conjunta por lo que tenemos razones para pensar que el orden del VAR siguiendo como criterio LR test sería dos. Por supuesto para un VAR sin lags no podemos tener una tabla parecida.

Concluimos que el orden del VAR podría ser 2 o 0, un VAR(2) tiene más sentido para buscar el proceso generador de los datos mientras que un VAR(0) como lo señalan los

criterios de información podría implicar ausencia de relaciones de dependencia temporal de las variables es decir que se mueven como un ruido blanco.

Se hicieron pruebas con otros órdenes de magnitud de los cuales un VAR(11) tuvo los mejores resultados siendo significativo de forma conjunta al 90 % (0.0600) pero no es significativo para retko y retmcd, por lo que al final nos quedaremos con un VAR(2) también para facilitar los calculos futuros.

Cuadro 15: Model Selection Criteria

Lag	LogL	LR	FPE	AIC	SC	HQ
0	-5961.967	NA	6175086.	24.14966	24.17519	24.15968
1	-3495.103	4893.778	294.4677*	14.19880*	14.30089*	14.23888*
2	-3491.207	7.682402	300.6167	14.21946	14.39811	14.28960
3	-3482.297	17.45953*	300.7294	14.21983	14.47504	14.32002
4	-3474.868	14.46613	302.6548	14.22619	14.55797	14.35644
5	-3471.422	6.669519	309.5466	14.24867	14.65702	14.40899
6	-3466.226	9.992701	314.3649	14.26407	14.74898	14.45445
7	-3459.173	13.47770	316.8727	14.27195	14.83343	14.49239
8	-3456.919	4.280396	325.6729	14.29927	14.93730	14.54976

Finalmente para terminar de contrastar el cuadro 15 muestra los criterios de selección para un VAR con las mismas variables en niveles, como vemos son análogos a los criterios para el VAR con la transformación lineal de las variables en logaritmos pero restando un lag, por lo que podemos aventurarnos a decir que nuestra elección de un VAR(2) y un VAR(0) puede estar justificada, por supuesto como proceso generador de datos un VAR(2) tiene más sentido.

Cuadro 16: Model Result, VAR(2)

	RETGOOG	RETKO	RETMCD
RETGOOG(-2)	-0.123909 (0.04653) [-2.66283]	-0.030709 (0.02882) [-1.06574]	-0.006541 (0.03232) [-0.20239]
RETKO(-2)	-0.002708 (0.07768) [-0.03486]	-0.071497 (0.04810) [-1.48629]	-0.046429 (0.05396) [-0.86051]
RETMCD(-2)	0.026656 (0.06965) [0.38273]	-0.068351 (0.04313) [-1.58484]	-0.065107 (0.04837) [-1.34592]
C	0.046959 (0.07380) [0.63631]	0.042425 (0.04570) [0.92837]	0.028897 (0.05126) [0.56376]
Model Information			
R-squared	0.014732	0.020591	0.008428
Adj. R-squared	0.008761	0.014655	0.002418
Sum sq. resids	1342.710	514.8759	647.7417
S.E. equation	1.646981	1.019879	1.143927
F-statistic	2.467164	3.468869	1.402366
Log likelihood	-955.0152	-715.8646	-773.1414
Akaike AIC	3.843748	2.885229	3.114795
Schwarz SC	3.877517	2.918997	3.148563
Mean dependent	0.041466	0.036443	0.025134
S.D. dependent	1.654243	1.027435	1.145313

b) Estimate a diagonal Multivariate GARCH model for those variables.

Solución:

Cuadro 17: Model Results, GARCH(1,1)

Variables		Coefficient	Std. Error	z-Statistic	Prob.
RETGOOG	RETGOOG(-2)	-0.123909	0.051231	-2.418622	0.0156
	RETKO(-2)	-0.002708	0.094466	-0.028665	0.9771
	RETMCD(-2)	0.026656	0.083522	0.319148	0.7496
	C	0.046959	0.079218	0.592779	0.5533
RETKO	RETGOOG(-2)	-0.030709	0.033059	-0.928910	0.3529
	RETKO(-2)	-0.071497	0.052972	-1.349713	0.1771
	RETMCD(-2)	-0.068351	0.049514	-1.380448	0.1674
	C	0.042425	0.051435	0.824843	0.4095
RETMCD	RETGOOG(-2)	-0.006541	0.034379	-0.190267	0.8491
	RETKO(-2)	-0.046429	0.058943	-0.787698	0.4309
	RETMCD(-2)	-0.065107	0.057467	-1.132960	0.2572
	C	0.028897	0.054369	0.531489	0.5951
Variance Equation Coefficients					
$GARCH = M + A * (RESID^2)' + B * GARCH(-1)$					
M	$M_{1,1}$	0.222878	0.122841	1.814363	0.0696
	$M_{1,2}$	0.038910	0.104393	0.372728	0.7094
	$M_{1,3}$	0.029760	0.030960	0.961245	0.3364
	$M_{2,2}$	0.124060	0.110598	1.121716	0.2620
	$M_{2,3}$	0.032726	0.059470	0.550304	0.5821
	$M_{3,3}$	0.074856	0.026489	2.825914	0.0047
A	$A_{1,1}$	0.032271	0.018052	1.787634	0.0738
	$A_{1,2}$	0.006932	0.018216	0.380527	0.7036
	$A_{1,3}$	0.042843	0.027439	1.561405	0.1184
	$A_{2,2}$	0.001489	0.010299	0.144573	0.8850
	$A_{2,3}$	0.009203	0.014584	0.630991	0.5280
	$A_{3,3}$	0.056879	0.020246	2.809363	0.0050
B	$B_{1,1}$	0.885835	0.059516	14.88387	0.0000
	$B_{1,2}$	0.882680	0.310568	2.842147	0.0045
	$B_{1,3}$	0.887693	0.083703	10.60523	0.0000
	$B_{2,2}$	0.879536	0.107252	8.200683	0.0000
	$B_{2,3}$	0.884531	0.200090	4.420674	0.0000
	$B_{3,3}$	0.889555	0.030111	29.54259	0.0000
Model Information					
Log likelihood		-2381.990	Schwarz criterion	9.920557	
Avg. log likelihood		-1.591176	Hannan-Quinn criterion	9.766682	
Akaike info criterion		9.667294			

En el cuadro 17 vemos la estimación de un modelo GARCH(1,1) para el VAR(2) de las variables retgoog, retko y retmcd, vemos que los coeficientes se mantienen en general para todas las variables y rezagos si los comparamos con los del VAR(2), si analizamos la parte de la ecuación de la varianza vemos los componentes de las matrices que eligen la especificación de la varianza compuesta, vemos que para el rezago GARCH(-1) todos los coeficientes son representativos por lo que la inclusión de este rezago en la ecuación de la varianza debe ser significativa en conjunto, la estimación de un GARCH(0,1) pierde significatividad por lo que debemos tolerar el componente ARCH de la ecuación de la varianza es este modelo.

Cuadro 18: Covariance Matrix

1/05/2018			
	RETGOOG	RETKO	RETMCD
RETGOOG	1.043876	0.242069	0.282621
RETKO	0.242069	0.228680	0.186145
RETMCD	0.282621	0.186145	0.160821
1/08/2018			
	RETGOOG	RETKO	RETMCD
RETGOOG	1.143897	0.328994	0.371836
RETKO	0.328994	0.327663	0.281074
RETMCD	0.371836	0.281074	0.253051
1/09/2018			
	RETGOOG	RETKO	RETMCD
RETGOOG	1.237786	0.365491	0.419084
RETKO	0.365491	0.414634	0.333616
RETMCD	0.419084	0.333616	0.337983
1/10/2018			
	RETGOOG	RETKO	RETMCD
RETGOOG	1.325918	0.380814	0.444106
RETKO	0.380814	0.491050	0.362697
RETMCD	0.444106	0.362697	0.416194
1/11/2018			
	RETGOOG	RETKO	RETMCD
RETGOOG	1.408647	0.387248	0.457358
RETKO	0.387248	0.558194	0.378793
RETMCD	0.457358	0.378793	0.488214
1/12/2018			
	RETGOOG	RETKO	RETMCD
RETGOOG	1.486304	0.389950	0.464376
RETKO	0.389950	0.617189	0.387701
RETMCD	0.464376	0.387701	0.554536
1/16/2018			
	RETGOOG	RETKO	RETMCD
RETGOOG	1.559200	0.391084	0.468092
RETKO	0.391084	0.669026	0.392632
RETMCD	0.468092	0.392632	0.615608
1/17/2018			
	RETGOOG	RETKO	RETMCD
RETGOOG	1.627626	0.391560	0.470060
RETKO	0.391560	0.714572	0.395361
RETMCD	0.470060	0.395361	0.671847

El cuadro 18 muestra las matrices de covarianza condicional para los primeros ocho periodos, el resto de periodos está en el archivo Eviews ejercicio2.wf1 se puede comprobar que las matrices de covarianza condicional son todas positivas definidas, por lo que podemos asegurar que el proceso para la covarianza es capaz de modelar la volatilidad del modelo VAR (Lütkepohl, 2005).

Podemos asegurar que el modelo GARCH es suficiente como para representar la volatilidad conjunta del modelo VAR.

c) Compare for the results obtained in exercise 1 and 2 for retgoog

Si consideramos el modelo VAR en general las variables no se causan las unas a las otras y tienen mucha independencia de ahí que en el cuadro 12 todos los criterios de información mostraron un lag 0 como solución para el orden del VAR esto se debe a las diferencias fuertes que existen entre las variables, esto se puede terminar de ver en un test de causalidad de Granger.

Cuadro 19: Exclusion Chi-squared Test Results

Dependent variable: RETGOOG			
Excluded	Chi-sq	df	Prob.
RETKO	0.001215	1	0.9722
RETMCD	0.146483	1	0.7019
All	0.154266	2	0.9258

Dependent variable: RETKO			
Excluded	Chi-sq	df	Prob.
RETGOOG	1.135792	1	0.2865
RETMCD	2.511722	1	0.1130
All	4.303385	2	0.1163

Dependent variable: RETMCD			
Excluded	Chi-sq	df	Prob.
RETGOOG	0.040961	1	0.8396
RETKO	0.740476	1	0.3895
All	0.868001	2	0.6479

Vemos en el cuadro 21 que las tres variables no causan a la Granger a las otras variables, es decir no ayudan a predecir a las otras variables, y por lo tanto no tienen capacidad explicativa a las otras variables, sin embargo como comprobamos en el ejercicio 1, la variable retgoog tiene un outlier de volatilidad importante que puede ser modelado como un proceso ARCH(1), es justamente este efecto el que modifica la 'volatilidad' del proceso VAR(2) con las otras variables, esta volatilidad que puede ser recogida por un proceso GARCH(1,1) significativo. El modelo también debe recoger información sobre la volatilidad de las otras variables.

Esto se puede ver también comparando los resultados para los coeficientes de la ecuación de la varianza que corresponden a retgoog, que son $(M_{1,1}, A_{1,1}$ y $B_{1,1})$ estos coeficientes recogen la información de la varianza de la variable retgoog sobre si misma y es significativa al 10 %, existen también efectos interesantes por parte de la variable retmcd sobre si misma lo que nos lleva a pensar que esta variable también tiene un outlier de volatilidad, lo que podemos ver es que GARCH como una generalización de ARCH captura los efectos ARCH de las variables individuales de un modelo VAR si existiera una mayor relación entre las variables, estos efectos serían más significativos y causarían a la granger a las otras variables o a sus volatilidades.

3. Use the Eviews data file argentinaactual.wfl

The file contains the following variables pbreal (for real GDP) and 30 and 60 days interest rates.

- a) Find the order of a VAR(p) using the growth of pbreal and the spread between the 60 and the 30 days interest rates.

Solución

Cuadro 20: ADF test, pbi_g

Valores críticos	estadístico t	Prob
1 % level	-3.491345	
5 % level	-2.888157	
10 % level	-2.581041	
ADF test	-6.202261	0.0000

Cuadro 21: ADF Test Results, spread

Valores críticos	Estadístico t	Prob
1 % level	-3.489659	
5 % level	-2.887425	
10 % level	-2.580651	
ADF test	-15.06046	0.0000

Vemos que ambas series parecen ser estacionarias, esto se debe a que en el caso de pbi_g ya tenemos una transformación de la variable con tendencia que es el pbi, así que podemos empezar a evaluar el orden del VAR.

Cuadro 22: VAR order selection criteria

Lag	LogL	LR	FPE	AIC	SC	HQ
0	18.89520	NA	0.002402	-0.355688	-0.301923	-0.333963
1	36.60649	34.30397*	0.001800	-0.644347	-0.483050*	-0.579171*
2	40.96457	8.257421	0.001787*	-0.651886*	-0.383057	-0.543259
3	43.53825	4.768084	0.001842	-0.621858	-0.245497	-0.469780
4	47.48223	7.140668	0.001845	-0.620678	-0.136786	-0.425150
5	48.98264	2.653362	0.001946	-0.568056	0.023369	-0.329076
6	50.24758	2.183683	0.002065	-0.510475	0.188480	-0.228045
7	55.70005	9.183114	0.002006	-0.541054	0.265434	-0.215172
8	58.50623	4.608037	0.002062	-0.515921	0.398099	-0.146588
9	61.27008	4.422167	0.002123	-0.489896	0.531654	-0.077113
10	63.03564	2.750555	0.002234	-0.442856	0.686227	0.013378
11	63.84708	1.229978	0.002401	-0.375728	0.860886	0.123957
12	63.98510	0.203398	0.002619	-0.294423	1.049722	0.248712
13	64.23477	0.357415	0.002854	-0.215469	1.236209	0.371118
14	65.41760	1.643510	0.003053	-0.156160	1.403049	0.473877
15	68.33233	3.927217	0.003153	-0.133312	1.533428	0.540176

El cuadro 22 nos muestra los criterios para elegir el orden del VAR, vemos que el test estadístico LR nos da 1 lag, mientras que los criterios de información FPE y AIC nos dan un lag diferente que SC y HQ, si recordamos, los criterios de información según Lütkepohl (2005) son más eficientes cuando lo que se busca es hacer una predicción, mientras que el test LR puede ser superior para encontrar el proceso generador de los datos, en este caso que los criterios de información también arrojan resultados diferentes, recordamos que FPE y AIC suelen tener resultados consistentes en muestras chicas, mientras que SC y HQ suelen tener resultados consistentes en muestras grandes.

Independientemente de estas consideraciones estimamos un VAR(2) que considere tanto los criterios de información como el test estadístico.

Cuadro 23: VAR(2), Chi-squared test statistics for lag exclusion

	PBI_G	SPREAD	Joint
Lag 1	25.68262 [0.0000]	25.41970 [0.0000]	50.88897 [0.0000]
Lag 2	0.594945 [0.7427]	10.35501 [0.0056]	10.90658 [0.0276]
df	2	2	4

Vemos que la especificación de un VAR(2) parece ser suficiente, ya que ambos rezagos son significativos a nivel conjunto y la significatividad solamente no se cumple en el caso del rezago dos para pbi_g, sin embargo, para contrastar este resultado hacemos una prueba a los residuos:

Cuadro 24: VAR(2) Residual Portmanteau Tests for Autocorrelations

Lags	Q-Stat	Prob.*	Adj Q-Stat	Prob.*	df
1	0.187946	—	0.189703	—	—
2	9.041630	—	9.210437	—	—
3	15.28274	0.0041	15.62986	0.0036	4
4	18.92496	0.0153	19.41217	0.0128	8
5	22.10432	0.0364	22.74587	0.0300	12
6	23.88031	0.0922	24.62633	0.0767	16
7	38.66162	0.0073	40.43209	0.0044	20
8	41.78498	0.0136	43.80531	0.0080	24
9	43.79681	0.0291	46.00003	0.0174	28
10	45.66586	0.0556	48.05981	0.0340	32
11	46.20960	0.1186	48.66521	0.0773	36
12	46.25217	0.2299	48.71310	0.1624	40
13	47.09506	0.3471	49.67133	0.2576	44
14	47.56958	0.4904	50.21652	0.3856	48
15	52.96814	0.4366	56.48582	0.3111	52
16	54.40130	0.5356	58.16823	0.3955	56
17	58.72931	0.5223	63.30476	0.3606	60
18	61.70685	0.5580	66.87782	0.3785	64
19	62.35868	0.6701	67.66880	0.4885	68
20	62.94527	0.7681	68.38870	0.5988	72

El cuadro 24 nos da el test de Portmanteau de autocorrelación de los residuos, se puede ver que a partir del rezago tres, algunos de los rezagos son significativos bajo la hipótesis nula de no autocorrelación de los residuos, estas autocorrelaciones en los residuos pueden indicar que el modelo no ha capturado completamente la estructura de dependencia temporal en los datos.

Si los residuos presentan autocorrelaciones significativas, esto sugiere que hay información adicional que no se está teniendo en cuenta en el modelo y que puede afectar la precisión de las estimaciones y las predicciones, por lo que es evidencia de que el VAR(2) puede tener ciertas deficiencias al capturar las correlaciones entre las variables, por lo que para contrastar la información vamos a estimar otro modelo.

Cuadro 25: VAR(9), Chi-squared test statistics for lag exclusion

Lags	PBI_G	SPREAD	Joint
Lag 1	38.15062 [0.0000]	9.299231 [0.0096]	52.36320 [0.0000]
Lag 7	14.01632 [0.0009]	2.683633 [0.2614]	15.67298 [0.0035]
Lag 8	7.882250 [0.0194]	4.388115 [0.1115]	12.07916 [0.0168]
Lag 9	7.209140 [0.0272]	5.142672 [0.0764]	12.97657 [0.0114]
df	2	2	4

Después de probar algunas especificaciones podemos ver en el cuadro 25 que aumentar los rezagos en un VAR(9) también nos da rezagos significativos de forma conjunta.

Cuadro 26: VAR(9) Residual Portmanteau Tests for Autocorrelations

Lags	Q-Stat	Prob.*	Adj Q-Stat	Prob.*
1	2.272134	—	2.294856	—
2	5.102303	—	5.182200	—
3	10.57309	—	10.82046	—
4	15.90095	—	16.36803	—
5	20.92549	—	21.65426	—
6	24.85866	—	25.83584	—
7	27.69647	—	28.88498	—
8	30.02677	—	31.41573	—
9	30.73000	—	32.18776	—
10	31.80794	0.1318	33.38416	0.0962
11	34.28439	0.1917	36.16328	0.1385
12	35.38195	0.3116	37.40883	0.2346
13	37.36210	0.4063	39.68149	0.3093
14	38.50059	0.5378	41.00319	0.4263
15	41.93121	0.5607	45.03218	0.4285
16	46.16577	0.5483	50.06383	0.3914
17	47.59590	0.6476	51.78339	0.4824
18	50.15976	0.6945	54.90327	0.5164
19	50.79125	0.7957	55.68108	0.6341
20	53.00880	0.8349	58.44617	0.6724

Si revisamos la prueba para los residuos, vemos que en este caso, el VAR(9) no nos permite rechazar la hipótesis nula de no autocorrelación de los residuos lo que indica que el modelo VAR(9) captura las relaciones entre las dos variables de mejor forma, sin embargo, la presencia de autocorrelaciones en los residuos implica que existe una dependencia serial entre los errores del modelo, sin embargo, hay que considerar que el hecho de que el valor p sea significativo en un determinado rezago no implica que el proceso VAR sea capaz de generar los datos.

Sin embargo, esto no significa necesariamente que el proceso VAR sea capaz de generar los datos de manera precisa. Es posible que haya autocorrelaciones en los residuos en rezagos más altos que no se capturan en el modelo VAR especificado. Además, hay otros aspectos a considerar, como la bondad de ajuste global del modelo que en este caso como vimos en el cuadro 27 parece ser significativo también.

Finalmente nos quedaremos con ambos modelos un VAR(2) como lo recomendado por los criterios de información y un VAR(9) que se desprende del hecho de mejorar el ajuste del modelo capturando las autocorrelaciones entre los residuos de las variables que el modelo VAR(2) no logro capturar.

Cuadro 27: VAR(9) Model Results

Variable	PBI_G	SPREAD
PBI_G(-1)	0.526307 (0.08549) [6.15637]	29.06643 (10.3726) [2.80224]
PBI_G(-7)	0.050203 (0.09394) [0.53441]	-11.63126 (11.3978) [-1.02048]
PBI_G(-8)	-0.267320 (0.10722) [-2.49328]	18.36831 (13.0087) [1.41200]
PBI_G(-9)	0.221503 (0.09686) [2.28681]	-6.188887 (11.7522) [-0.52661]
SPREAD(-1)	2.89×10^{-5} (0.00081) [0.03561]	0.097484 (0.09859) [0.98874]
SPREAD(-7)	0.002213 (0.00060) [3.69779]	-0.092033 (0.07262) [-1.26732]
SPREAD(-8)	-0.000668 (0.00037) [-1.79068]	-0.054829 (0.04523) [-1.21224]
SPREAD(-9)	-0.000416 (0.00029) [-1.44233]	-0.076910 (0.03500) [-2.19731]
C	0.001121 (0.00231) [0.48617]	0.917302 (0.27973) [3.27926]
R-squared	0.351221	0.197039
Adj. R-squared	0.294805	0.127216
Sum sq. resids	0.030021	441.9398
S.E. equation	0.018064	2.191733
F-statistic	6.225594	2.821991
Log likelihood	266.7972	-217.8535
Akaike AIC	-5.104896	4.492148
Schwarz SC	-4.871865	4.725179
Mean dependent	0.005962	1.012874
S.D. dependent	0.021511	2.346034

Cuadro 28: VAR(2) Model Results

Variable	PBI_G	SPREAD
PBI_G(-1)	0.494813 (0.09774) [5.06280]	38.77646 (15.5066) [2.50065]
PBI_G(-2)	-0.061002 (0.09747) [-0.62585]	-30.27181 (15.4647) [-1.95748]
SPREAD(-1)	$9,59 \times 10^{-5}$ (0.00034) [0.28361]	0.247064 (0.05363) [4.60660]
SPREAD(-2)	0,000119 (0.00029) [0.40573]	0.111779 (0.04638) [2.41015]
C	0.003651 (0.00201) [1.81301]	0.697535 (0.31951) [2.18314]
R-squared	0.228297	0.218175
Adj. R-squared	0.198328	0.187813
Sum sq. resids	0.037750	950.2763
S.E. equation	0.019144	3.037430
F-statistic	7.617755	7.185750
Log likelihood	276.5349	-270.6749
Akaike AIC	-5.028425	5.105091
Schwarz SC	-4.904252	5.229264
Mean dependent	0.006979	0.996574
S.D. dependent	0.021382	3.370375

Los cuadros 27 y 28 muestran los modelos VAR(9) Y VAR(2) respectivamente, que son los modelos que vamos a considerar.

b) Establish whether the spread is a valid predictor of the growth in pbreak.

Solución:

Para evaluar si el spread tiene capacidad de predicción sobre pbi_g es necesario evaluar la relación entre las variables, puede existir varios tipos de relaciones entre las variables, así que empezamos por correr un test de cointegración para detectar relaciones de largo plazo que pueden haber sido descartadas en pbi_g al quitarle la tendencia del pbi, si bien un test de cointegración puede tener más sentido en variables con una tendencia y en este caso tenemos variables estacionarias, de igual manera nos puede ayudar a descubrir relaciones entre las variables y servirnos para contrastar información.

Cuadro 29: VAR(2) Johansen test, Unrestricted Cointegration Rank Test (Trace)

Hypothesized No. of CE(s)	Eigenvalue	Trace Statistic	0.05 Critical Value	Prob.**
None *	0.575567	113.1293	15.49471	0.0001
At most 1 *	0.181500	21.43019	3.841466	0.0000

Trace test indicates 2 cointegrating eqn(s) at the 0.05 level

* denotes rejection of the hypothesis at the 0.05 level

**MacKinnon-Haug-Michelis (1999) p-values

Cuadro 30: VAR(9) Johansen test, Unrestricted Cointegration Rank Test (Trace)

Hypothesized No. of CE(s)	Eigenvalue	Trace Statistic	0.05 Critical Value	Prob.**
None *	0.358334	69.13688	15.49471	0.0000
At most 1 *	0.219392	24.76821	3.841466	0.0000

Trace test indicates 2 cointegrating eqn(s) at the 0.05 level

* denotes rejection of the hypothesis at the 0.05 level

**MacKinnon-Haug-Michelis (1999) p-values

Los cuadros 29 y 30 arrojan los resultados de una prueba sin restricción de rango de cointegración de Johansen para los dos modelos VAR, bajo las hipótesis de que no existen o que existe como máximo una ecuación de cointegración, el test indica que hay 2 ecuaciones de cointegración en el modelo, esto implica que existe una relación de equilibrio a largo plazo entre las variables pbi_g y spread, esto es evidencia de que las dos variables están vinculadas entre sí, sin embargo hay que tomar con cuidado este resultado debido a que como vimos anteriormente tanto pbi_g y spread no tienen una tendencia, esto puede modificar la interpretación de la cointegración.

La presencia de dos ecuaciones de cointegración implica que hay dos relaciones lineales independientes que mantienen un equilibrio a largo plazo entre las variables. Por lo que podemos decir que si existe una relación entre las variables si bien aún no podemos determinar la dirección de las relaciones y ni siquiera un equilibrio debido a la estacionariedad de ambas series en el VAR, esto sugiere la existencia de una relación económica más profunda entre el spread de las tasas de interés y el crecimiento del PBI.

Cuadro 31: VAR(2) Granger causality, Exclusion Restriction Test: Dependent variable - PBI_G

Excluded	Chi-sq	df	Prob.
SPREAD	0.204865	2	0.9026
All	0.204865	2	0.9026

Cuadro 32: VAR(2) Granger causality, Exclusion Restriction Test: Dependent variable - SPREAD

Excluded	Chi-sq	df	Prob.
PBI_G	6.993625	2	0.0303
All	6.993625	2	0.0303

Los cuadros 31 y 32 nos dan los resultados de un test de causalidad a la Granger entre las dos variables. Para el modelo VAR(2), vemos, especialmente en el cuadro 31 que no podemos rechazar la hipótesis nula de significatividad de spread sobre pbi_g por lo que según esta especificación el spread no tendría poder predictivo sobre pbi_g.

Cuadro 33: VAR(9) Granger causality, Exclusion Restriction Test: Dependent variable - PBI_G


Excluded	Chi-sq	df	Prob.
SPREAD	14.43414	4	0.0060
All	14.43414	4	0.0060

Cuadro 34: VAR(9) Granger causality, Exclusion Restriction Test: Dependent variable - SPREAD

Excluded	Chi-sq	df	Prob.
PBI_G	10.84783	4	0.0283
All	10.84783	4	0.0283

En los cuadros 33 y 34 vemos el resultado del test de causalidad de Granger para el modelo VAR(9), en este caso vemos que la variable spread si tiene poder predictivo sobre pbi_g ya que podemos rechazar la hipótesis nula en el cuadro 33 y también en el cuadro 34, por lo que la variable pbi_g también tendría poder predictivo sobre spread. Esta aparente contradicción en los modelos VAR(2) y VAR(9) podría implicar una mala especificación de alguno de los modelos o que existe algo más que está afectando el VAR(9) que no logra ser atrapado por el VAR(2).

Figura 5: spread



En la figura 5 vemos la variable spread, notamos que a pesar de ser estacionaria en su conjunto tiene una alta volatilidad en ciertas regiones, este debe ser el efecto que ocasiona que el VAR(2) como nos lo sugieren los criterios de información y el test estadístico no sean suficientes como para capturar el proceso generador de los datos de la mejor forma, ya que como vimos en el ejercicio anterior, a pesar de la estacionariedad un modelo VAR podría capturar efectos producto de la volatilidad de la varianza de una de las variables endógenas del VAR, por lo que contrario a lo que sugieren los test de lag exclusion y considerando que el test de cointegración permite pensar en una relación entre las variables podríamos decir que es el modelo VAR(9) el que captura mejor la relación entre las variables.

Siguiendo esto la variable spread tiene cierto poder predictivo sobre pbi_g siguiendo el VAR(9) como en el cuadro 27.

- c) Find the impulse response functions for shocks to both the spread and growth in pbreal. Compare your results with those obtained doing local projections. Discuss the differences and similarities between these two methods.

Solución:

Calculamos la función de impulso respuesta para ambos modelos.

Figura 6: VAR(2) Impulse response

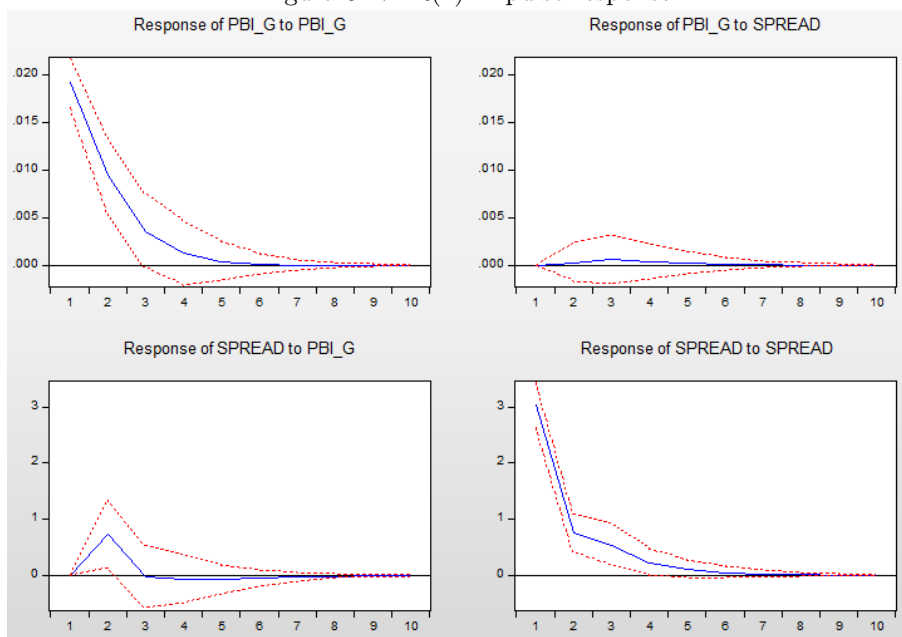
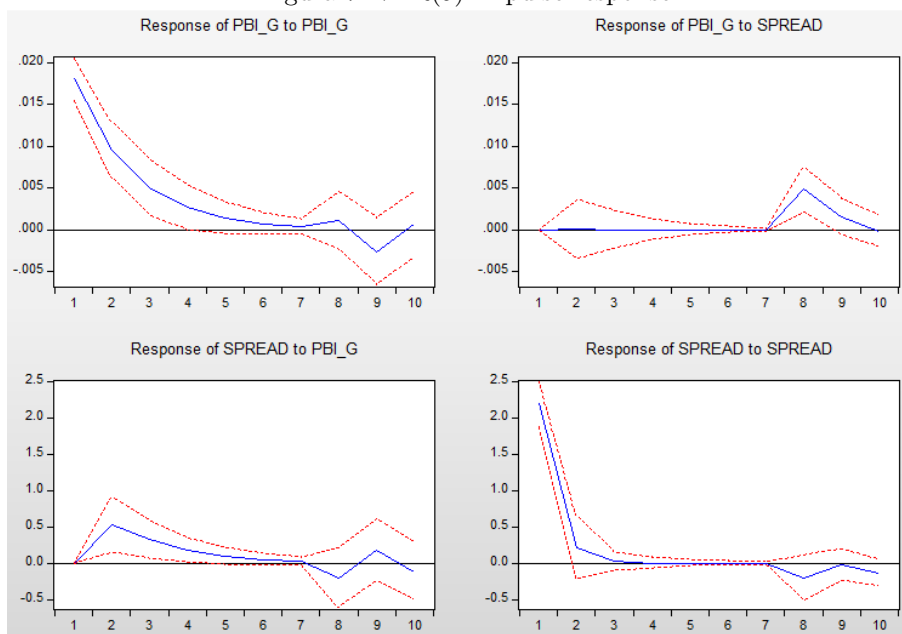


Figura 7: VAR(9) Impulse response



Las figuras 6 y 7 muestran las funciones de impulso respuesta para el modelo VAR(2) y VAR(9) respectivamente, como respuesta a innovaciones de ± 2 desviaciones estándar. Vemos que el VAR(2) parece no capturar un movimiento posterior al impulso inicial que el VAR(9) si captura, de igual manera esto se debe a que el VAR(9) al considerar más rezagos permite que la volatilidad inicial que se aprecia en la figura 5 esté capturada también.

Figura 8: VAR(2) Local projections

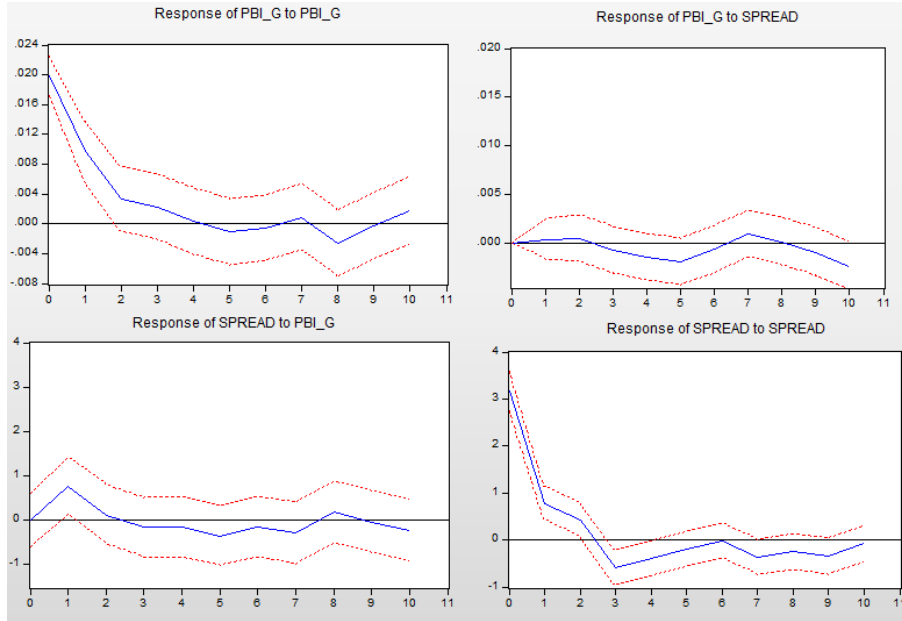
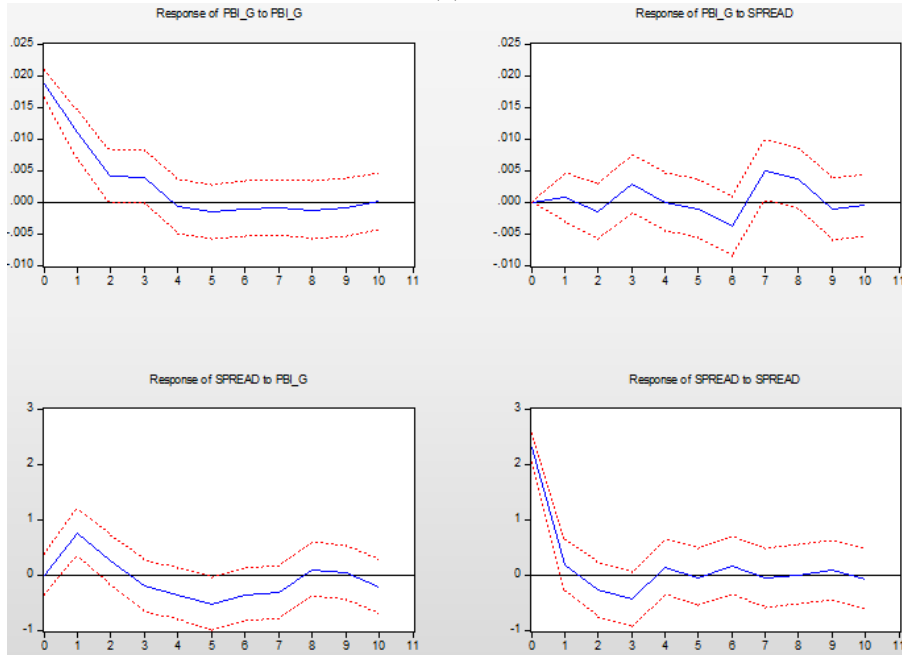


Figura 9: VAR(9) Local projections



Las figuras 8 y 9 muestran los gráficos de una función impulso respuesta realizada a través de local projections, si comparamos las figuras 6 y 8 para el modelo VAR(2), vemos que en la figura 6, la función de impulso respuesta no es capaz de atrapar el shock que aparece en el periodo 8, mientras que local projections si atrapa el shock, esto se debe al algoritmo que utiliza ya que se basa en realizar estimaciones de regresiones en diferentes horizontes de tiempo para capturar los efectos dinámicos de un choque en una variable de interés. A diferencia de la función impulso respuesta tradicional que se centra en estimar los efectos a corto plazo, las local projections permiten examinar cómo evolucionan los efectos a lo largo del tiempo, por lo que son más sensibles a cambios en la volatilidad, como vimos anteriormente el modelo VAR(2) no logra atrapar algunos movimientos de las variables.

Si analizamos las figuras 7 y 9, que tienen la función impulso respuesta tradicional y

la función impulso respuesta de local projections respectivamente, vemos que el modelo VAR(9) es capaz de capturar un poco mejor el shock del periodo 8 (o 9) por lo que ambos gráficos se parecen más, este es un argumento a favor del modelo VAR(9) para este tipo de análisis.

Sin embargo, la elección del orden del VAR y si se prefiere un función de impulso respuesta tradicional o una función de impulso respuesta a través de proyecciones locales dependerá del análisis que se desea hacer, una función de impulso respuesta tradicional se enfoca más en los efectos de corto plazo, mientras que proyecciones locales descuenta de mejor forma valores futuros.

4. Use the Eviews data file named uncerindex.wfl

The data file contains the variables *ersf* : the excess (with respect to the risk-free rate) return inclusive of dividends yields of stock prices, *pd* : the Price-Dividend ratio, *vrp3* : a volatility index, *exret* : ex-dividends returns, and *deltasent12* : a variable that captures consumer confidence.

- a) Estimate a regression of *ersf* on *vrp3* and *deltasent12* to determine if those variables (endogeneity issues aside), can be considered determinants of the excess return (the Risk Premium).

Solución:

Antes de correr la regresión es necesario verificar estacionariedad para revisar si es necesario diferenciar las variables y asegurar que se cumplan los supuestos de una regresión y resultados válidos.

Cuadro 35: ADF test *ersf*

Valores críticos	estadístico t	Prob.
1 % level	-3.983055	
5 % level	-3.422016	
10 % level	-3.133835	
ADF test	-18.20642	0.0000

Cuadro 36: ADF test *vrp3*

Valores críticos	estadístico t	Prob.
1 % level	-3.984420	
5 % level	-3.422679	
10 % level	-3.134227	
ADF test	-3.977047	0.0102

Cuadro 37: ADF test *deltasent12*

Valores críticos	estadístico t	Prob.
1 % level	-3.984269	
5 % level	-3.422606	
10 % level	-3.134184	
ADF test	-4.270202	0.0039

Los cuadros 35, 36 y 37 nos dan los test Dickey Fuller para las tres variables, vemos que para la variable *deltasent12* el estadístico del test sigue siendo mucho más grande en valor absoluto que los valores críticos al 1 %, 5 y 10 % por lo que no es necesario diferenciarla, sin embargo, para la variable *vrp3*, el valor del estadístico t conjunto no es superior al estadístico al 5 % por lo que podría ser buena idea diferenciar la variable antes de utilizarla en la regresión.

Cuadro 38: Regression Results

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	0.496103	0.210550	2.356223	0.0190
DVRP3	-0.064822	0.024470	-2.649039	0.0084
DELTASENT12	0.068705	0.021613	3.178886	0.0016
R-squared	0.033140	Mean dependent var	0.510657	
Adjusted R-squared	0.030416	S.D. dependent var	4.065389	
S.E. of regression	4.003085	Akaike info criterion	5.617594	
Sum squared resid	5688.764	Schwarz criterion	5.639318	
Log likelihood	-1000.741	Hannan-Quinn criter.	5.626235	
Durbin-Watson stat	1.928113			

La tabla 38 nos da el resultado de una regresión por OLS entre *ersf* como variable dependiente y *vrp3* y *deltasent12* como variables explicativas, se diferencié la variable *vrp3* (*dvrp3*) para asegurar que esté en el mismo orden de integración que las otras variables de acuerdo a los resultados de Dickey-Fuller, parece ser que existe un efecto significativo entre los cambios en la volatilidad y el exceso de retorno de los precios de los activos con un impacto negativo, y un impacto positivo representativo de la variable que captura la confianza del consumidor.

Estos resultados deben ser utilizado con mucho cuidado y solamente como una aproximación para decir que existe una relación significativa, ya que una estimación así de sencilla por OLS hace muchos supuestos que podrían afectar los resultados, solamente chequeamos estacionariedad de las variables, pero estas podrían estar cointegradas y en ese caso deberíamos calcular un modelo VEC que considere esa relación entre las variables, además no estamos considerando efectos ARCH en la volatilidad de ninguna de las variables y es muy probable que los desvíos presenten heterocedasticidad que no permita realizar inferencia, por lo que aún sin considerar endogeneidad se debe tener cuidado con los resultados de esta regresión.

- b) Estimate a regression of *ersf* (the Risk Premium) on *pd*, *vrp3*, *exret* and *deltasent12* **past values** to determine if those variables have predictive power for future Risk Premia.

Solución:

Para resolver esto, volvemos a considerar un test de estacionariedad para las variables nuevas y debemos encontrar los rezagos relevantes del proceso que genera los datos de *deltasent12*.

Cuadro 39: ADF test, *exret*

Valores críticos	estadístico t	Prob.
1 % level	-3.984726	
5 % level	-3.422828	
10 % level	-3.134315	
ADF test	-17.77885	0.0000

Cuadro 40: ADF test, *pd*

Valores críticos	estadístico t	Prob.
1 % level	-3.982988	
5 % level	-3.421983	
10 % level	-3.133816	
ADF test	-1.767586	0.7186

Los cuadros 39 y 40 nos dan los resultados de un test de estacionariedad de Dickey Fuller para las nuevas variables que vamos a incluir en el modelo, vemos que la variable *pd* no es estacionaria, por lo que vamos a utilizar $pd_{growth} = \log(pd) - \log(pd(-1))$ que si es estacionaria para representar los precios, es necesario recordar que se debe utilizar variables en el mismo orden de integración, es decir, estacionarias

Además de chequear la estacionariedad de estas variables, es necesario verificar los rezagos representativos de la variable deltasent12 para aproximar los valores pasados de la variable, para lo que calculamos un modelo ARMA y vamos buscando los rezagos significativos, después de algunas pruebas y de chequear el correlograma y la significatividad conjunta de los rezagos decidimos quedarnos con un modelo ARMA(1,12) como el que genera los datos, utilizamos esta información para conocer cuales son los rezagos representativos de la variable para aproximar los valores pasados a través de un proceso.

Cuadro 41: deltasent12 ARMA(1,12)

Variable	Coefficient	Std. Error	t-Statistic	Prob.
AR(1)	0.948885	0.017282	54.90753	0.0000
MA(12)	-0.967983	0.078488	-12.33286	0.0000
SIGMASQ	16.13931	1.182502	13.64845	0.0000
R-squared	0.836079	Mean dependent var		-0.076503
Adjusted R-squared	0.835176	S.D. dependent var		9.936188
S.E. of regression	4.033943	Akaike info criterion		5.724037
Sum squared resid	5906.989	Schwarz criterion		5.756026
Log likelihood	-1044.499	Hannan-Quinn criter.		5.736748
Durbin-Watson stat	1.990792			

Figura 10: VAR(9) Impulse response

Autocorrelation	Partial Correlation	AC	PAC	Q-Stat	Prob
		1 0.002	0.002	0.0009	
		2 -0.105	-0.105	4.0468	
		3 -0.033	-0.033	4.4492	0.035
		4 0.001	-0.010	4.4500	0.108
		5 -0.089	-0.097	7.4162	0.060
		6 0.045	0.043	8.1659	0.086
		7 -0.003	-0.023	8.1685	0.147
		8 0.078	0.083	10.478	0.106
		9 0.063	0.065	11.979	0.101
		10 -0.046	-0.039	12.780	0.120
		11 -0.005	0.025	12.788	0.172
		12 0.055	0.048	13.958	0.175
		13 -0.066	-0.054	15.624	0.156
		14 0.031	0.050	15.991	0.192
		15 0.017	-0.005	16.106	0.243
		16 0.052	0.059	17.147	0.248
		17 0.016	0.020	17.245	0.304
		18 0.039	0.037	17.819	0.335
		19 -0.055	-0.030	19.011	0.328
		20 0.026	0.022	19.266	0.376
		21 0.049	0.058	20.219	0.382
		22 -0.039	-0.036	20.828	0.407
		23 0.014	0.023	20.902	0.465
		24 0.034	0.012	21.369	0.498
		25 -0.025	-0.021	21.615	0.544
		26 -0.030	-0.028	21.979	0.581
		27 0.047	0.040	22.861	0.586
		28 -0.099	-0.109	26.755	0.422
		29 0.026	0.029	27.015	0.463
		30 0.034	0.003	27.484	0.492
		31 0.092	0.104	30.876	0.371
		32 0.077	0.075	33.260	0.311
		33 0.085	0.093	36.154	0.240
		34 -0.024	0.029	36.379	0.272
		35 -0.038	-0.025	36.964	0.291
		36 -0.019	0.011	37.106	0.328

El cuadro 41 y la figura 8 muestran los resultados del modelo ARMA(1,12) como el proceso generador de los datos para la serie deltasent12 se puede ver que el modelo ARMA(1,12) es capaz de capturar el proceso, al eliminar la estructura del correlograma, además los rezagos son representativos de forma individual y conjunta, por lo que con-

cluimos que para la variable que representa la confianza del consumidor (deltasent12) los rezagos representativos son el (-1) y el (-12).

Cuadro 42: Regression Results

Variable	Coefficient	Std. Error	t-Statistic	Prob.
PDGROWTH	97.43735	0.846851	115.0584	0.0000
VRP3	-0.012862	0.002486	-5.174946	0.0000
EXRET	0.588704	0.050656	11.62158	0.0000
DELTASENT12(-1)	0.013885	0.003566	3.894002	0.0001
DELTASENT12(-12)	0.023782	0.003441	6.911532	0.0000
R-squared	0.976710	Mean dependent var		0.559003
Adjusted R-squared	0.976429	S.D. dependent var		4.094895
S.E. of regression	0.628683	Akaike info criterion		1.924389
Sum squared resid	130.8251	Schwarz criterion		1.981191
Log likelihood	-318.2973	Hannan-Quinn criter.		1.947032
Durbin-Watson stat	0.246370			

El cuadro 42 nos da los resultados de la regresión que considera también las variables exret y pdgrowth junto con los valores pasados de deltasent12 representados por los rezagos representativos del modelo ARMA que genera la serie, se hicieron varios experimentos con la constante pero en ningún caso resultó ser representativa por lo que se la sacó de la estimación, además dado que pd no era estacionaria, se decidió usar pdgrowth, en el caso de vrp3 que si bien era estacionaria al 10 % de significatividad no lo era al 5 % por lo que decidimos diferenciarla en el literal anterior, sin embargo en este caso la inclusión de dvrp3 (vrp3 diferenciada) no es representativa por lo que decidimos dejarla en niveles debido a que además mantener cierta tendencia en vrp3 puede ayudar al ajuste del modelo, utilizamos pdgrowth debido a la no estacionariedad de pd.

Vemos en el cuadro 42 que el crecimiento de los precios (pdgrowth) tiene un coeficiente positivo representativo sobre la prima de riesgo (ersf) lo que además también anuncia la teoría, el índice de volatilidad (vrp3) en niveles tiene una relación negativa representativa, los retornos después de dividendos (exret) tiene un coeficiente positivo representativo, y los dos rezagos representativos de la variable que captura la confianza del consumidor (deltasent12) también tienen relaciones positivas representativas si bien pequeñas, esto se debe a que se eligieron los rezagos representativos del proceso que genera los datos por lo que son los que mejor capturan la información de la variable deltasent12 en su conjunto. Si consideramos los coeficientes de bondad del ajuste de esta ecuación R^2 y los comparamos con el obtenido en el cuadro 40, se puede ver que la especificación de la regresión aumentó dramáticamente con la inclusión del crecimiento de los precios y los retornos después de dividendos.

Concluimos que existe una relación entre todas estas variables con la prima de riesgo, por lo que si bien sería necesario evaluar otro tipo de relaciones como las de largo plazo a través de las ecuaciones de cointegración, y un test de causalidad a la Granger y evaluar endogeneidad, podemos de igual manera aventurarnos a decir, que estas variables tienen poder predictivo sobre los valores futuros de la prima de riesgo, si bien el alcance de esta relación requeriría otro tipo de pruebas.

- c) Estimate a *Threshold* regression of *ersf* on *pd*, *vrp3*, *exret* **past values** to determine if those variables have predictable power for future Risk Premia. Use **past deltasent12** as your threshold and analyze whether your results differ between regimes.

Solución:

Cuadro 43: Threshold Regression Results

Variable	Coefficient	Std. Error	t-Statistic	Prob.
DELTASENT12(-12) < -8.700001 – 50 obs				
PDGROWTH	95.88175	1.972293	48.61436	0.0000
VRP3	-0.006818	0.004667	-1.461025	0.1450
EXRET(-1)	-0.112111	0.131014	-0.855723	0.3928
-8.700001 <= DELTASENT12(-12) – 287 obs				
PDGROWTH	97.41465	1.181366	82.45934	0.0000
VRP3	-0.013445	0.003995	-3.365032	0.0009
EXRET(-1)	0.687054	0.073622	9.332175	0.0000
R-squared	0.966968	Mean dependent var	0.557568	
Adjusted R-squared	0.966469	S.D. dependent var	4.088882	
S.E. of regression	0.748738	Akaike info criterion	2.276789	
Sum squared resid	185.5615	Schwarz criterion	2.344802	
Log likelihood	-377.6389	Hannan-Quinn criter.	2.303898	
Durbin-Watson stat	0.474357			

En el cuadro 43 se puede ver el resultado de una Threshold regression que considera los rezagos significativos de *deltasent12* como umbral como una aproximación de los valores pasados de *deltasent12*, además de considerar los valores pasados de *exret*, se hicieron varias especificaciones de la regresión y se decidió utilizar esta al final que considera *pdgrowth* debido a la tendencia de la variable *pd* en niveles y sin considerar una constante, ya que si bien había resultados parecidos en las otras regresiones, en esta se puede apreciar de mejor forma los cambios de régimen.

Vemos que el modelo identifica dos regímenes, uno donde los valores pasados de *deltasent12* están por debajo de -8.700001 con 50 observaciones y el otro régimen por sobre -8.700001 con 287 observaciones, se puede ver que en el primer régimen el crecimiento de los precios tiene un valor positivo significativo, mientras que el índice de volatilidad y los valores pasados de los retornos *porst* dividendos tienen efectos negativos sobre la prima de riesgo aunque no son representativos. Esta representatividad cambia cuando pasamos al segundo régimen, donde todas las variables son representativas, y para el caso de la volatilidad y los retornos *ex* dividendos el coeficiente también aumenta en este régimen, en el caso del crecimiento de los precios la significatividad se mantiene y el coeficiente aumenta.

Podría interpretarse diciendo que un cambio en la confianza de los consumidores modifica como la volatilidad y los retornos *post* dividendos afectan a la prima de riesgo, un aumento en la confianza de los consumidores, aumentaría la demanda, lo que a su vez aumenta los precios y las utilidades lo que podría ser uno de los efectos que hace que los retornos *post* dividendos se vuelvan significativos en el segundo régimen, de igual manera este resultado que aumenta la demanda al mover la economía en su conjunto tiene el potencial de aumentar la volatilidad hasta el punto de volverla significativa en el otro régimen como variable explicativa de la prima de riesgo. Por lo que podemos concluir que existe una relación entre la confianza de los consumidores y la prima de riesgo con el potencial de hacer un cambio estructural donde otras variables empezarían a ser importantes, en este caso los retornos pasados *ex* dividendos y el índice de volatilidad como determinantes de la prima de riesgo.

- d) Estimate a Markov Switching regression of *ersf* on past *pd*, *vrp3*, *exret* and *deltasent12* values to determine if those variables have predictive power for future Risk Premia. Compare the results and the separation of the regimes with those obtained in (c).

Solución:

Para realizar esta regresión que pide los valores pasados de las variables, será necesario encontrar los rezagos representativos de las variables, después de una extensa búsqueda llegamos a que las variables *pdgrowth* y *exret* no tienen una estructura definida en las funciones de autocorrelación ni en la función de autocorrelación parcial por lo que la

variable por si misma captura la información para generar la serie, en el caso de estas dos variables utilizaremos un solo rezago para representar los valores pasados. En el caso de la variable deltasent12 utilizaremos la estructura ya encontrada antes y para el caso de vrp3 el proceso generador de datos requiere un modelo ARMA(24,24) dado que este orden es demasiado grande para realizar cálculos, vamos a utilizar solamente el primer rezago con el objetivo de descubrir esa relación.

Cuadro 44: Markov Switching Regression Results

Variable	Coefficient	Std. Error	z-Statistic	Prob.
Regime 1				
PDGROWTH(-1)	15.29571	15.34932	0.996507	0.3190
VRP3(-1)	0.078409	0.113724	0.689473	0.4905
EXRET(-1)	-6.982021	2.315679	-3.015107	0.0026
DELTASENT12(-1)	0.149317	0.057120	2.614098	0.0089
DELTASENT12(-12)	0.085704	0.055340	1.548689	0.1215
Regime 2				
PDGROWTH(-1)	-12.78670	4.985217	-2.564924	0.0103
VRP3(-1)	0.095716	0.014173	6.753464	0.0000
EXRET(-1)	0.169582	0.279762	0.606164	0.5444
DELTASENT12(-1)	0.000368	0.019674	0.018728	0.9851
DELTASENT12(-12)	-0.002331	0.018738	-0.124387	0.9010
Common				
LOG(SIGMA)	1.031428	0.057225	18.02417	0.0000
Transition Matrix Parameters				
P11-C	-1.212952	0.594645	-2.039792	0.0414
P21-C	-1.982131	0.365302	-5.426007	0.0000
Mean dependent var	0.557568	S.D. dependent var	4.088882	
S.E. of regression	3.982159	Sum squared resid	5169.575	
Durbin-Watson stat	1.966507	Log likelihood	-908.8091	
Akaike info criterion	5.470677	Schwarz criterion	5.618040	
Hannan-Quinn criter.	5.529414			

Cuadro 45: Markov Switching Regression Results

Variable	Coefficient	Std. Error	z-Statistic	Prob.
Regime 1				
PDGROWTH	97.40749	0.830265	117.3210	0.0000
VRP3	-0.012564	0.003299	-3.807997	0.0001
EXRET	0.147881	0.079467	1.860914	0.0628
DELTASENT12	0.001729	0.004258	0.406029	0.6847
Regime 2				
PDGROWTH	98.21381	0.977416	100.4831	0.0000
VRP3	0.005241	0.002497	2.098989	0.0358
EXRET	0.800755	0.043790	18.28619	0.0000
DELTASENT12	0.020695	0.003465	5.972422	0.0000
Common				
LOG(SIGMA)	-0.776947	0.039153	-19.84379	0.0000
Transition Matrix Parameters				
P11-C	4.154492	0.641729	6.473905	0.0000
P21-C	-4.672479	0.756974	-6.172575	0.0000
Mean dependent var	0.531994	S.D. dependent var	4.129417	
S.E. of regression	0.479670	Sum squared resid	77.53796	
Durbin-Watson stat	0.406150	Log likelihood	-241.1702	
Akaike info criterion	1.457631	Schwarz criterion	1.579917	
Hannan-Quinn criter.	1.506326			

Los cuadros 44 y 45 muestran el resultado del modelo Markov Switching, el cuadro 44 muestra el modelo para los valores pasados de las variables explicativas donde en el caso de *deltasent12* se utilizaron los dos rezagos significativos, el cuadro 45 muestra el modelo para las variables contemporáneas. Se puede ver en el cuadro 45 que todas las variables son representativas en el régimen 1 excepto *deltasent12*, en el régimen 2, la variable *deltasent12* se vuelve representativa, ese cuadro pretende solamente motivar el análisis.

Si analizamos el cuadro 44 veremos el resultado de la regresión del modelo Markov switching que considera los valores pasados de las variables exxplicativas, nótese que en el régimen 1 el crecimiento de los precios no son significativos, y pasan a serlo en el régimen 2, lo mismo sucede con el índice de volatilidad (*vrp3*) mientras que los retornos post dividendos (*exret*) y el índice de confianza del consumidor (*deltasent12*) son significativas en el régimen 1 y pierden su significatividad en el régimen 2.

El modelo de regresión Markov Switching incorpora la posibilidad de cambios de régimen, asume que los datos son generados por un proceso de Markov que no es observable con múltiples regímenes, en este caso y para hacerlo comparable con el modelo Threshold utilizamos solamente 2 regímenes, para Markov Switching cada régimen representa un diferente estado o condición y la transición entre los regímenes depende de una matriz de probabilidades de transición, esto permite ver la relación que las variables explicativas tienen sobre la variable explicada en contextos distintos, al igual que en el modelo Threshold.

La diferencia principal es que en Threshold se decide un umbral arbitrario, mientras que el modelo de Markov Switching asume de antemano que las relaciones entre las variables pueden cambiar y de esta manera estima los regímenes que puedan existir. Vemos en la tabla 43 que después de que los valores pasados de la confianza del consumidor atraviezan el umbral definido, la volatilidad y los valores pasados de los retornos se vuelven significativos y aumentan su impacto sobre la prima de riesgo, en el caso del modelo de Switching sucede lo mismo a grandes rasgos, los valores pasados de los retornos post dividendos es significativa en el primer régimen donde los valores pasados de la confianza del consumidor es representativa, esto podría ser equivalente al regimen post umbral en el modelo Threshold, lo mismo sucede para la volatilidad siendo representativa en un régimen y no en el otro.

Nótese que al incluir los valores pasados del crecimiento de los precios estos también cambian en impacto y representatividad entre los dos regímenes, concluimos que existe una relación entre estas variables y la prima de riesgo, que esta relación puede cambiar en magnitud e importancia durante el periodo examinado, en el caso de Threshold diríamos que shocks en la confianza del consumidor tienen el potencial de cambiar la relación entre estas variables y la prima de riesgo, mientras que en Switching podríamos decir que este efecto que puede provocar los cambios en la confianza del consumidor está recogido en la matriz de transición que define dos regímenes que no son necesariamente secuenciales sino que existen durante el periodo examinado, momentos donde la magnitud de los valores pasados de la confianza del consumidor provocan una relación y otros momentos donde el efecto de esta variable modifica la relación de las otras variables sobre la prima de riesgo.

5. Use the Eviews data file named AnnLee.wfl

The data file contains the variables *EX3MHOLD12*, *EX3MHOLD24*, *EX3MHOLD60*, *EX3MHOLD120* representing the excess (with respect to the 3 months rate) realized returns of holding a 3 months bond of maturity 12, 24, 60 and 120 months, respectively.

- a) Use the Kalman filter to extract common factor that explains the movements of those returns. Store the common factor

Solución:

Para utilizar el filtro de Kalman primero es necesario definir un modelo state-space, debido a que queremos encontrar el factor común entre series que pueden considerarse transformaciones lineales de sí mismas tendremos que considerar una correlación entre

los errores de las ecuaciones de estado y las ecuaciones de señal. Definimos el modelo de la siguiente manera:

Las ecuaciones de señal o variables observadas como función de un componente no observado (sv1...sv4).

Ecuaciones de Señal:

$$ex3mhold12_t = \alpha_1 + \beta_1 sv1_t + u_1$$

$$ex3mhold24_t = \alpha_2 + \beta_2 sv2_t + u_2$$

$$ex3mhold60_t = \alpha_3 + \beta_3 sv3_t + u_3$$

$$ex3mhold120_t = \alpha_4 + \beta_4 sv4_t + u_4$$

Ecuaciones de estado:

$$sv1_t = \gamma_1 + \delta_1 sv1_{t-1} + v_1$$

$$sv2_t = \gamma_2 + \delta_2 sv1_{t-1} + v_2$$

$$sv3_t = \gamma_3 + \delta_3 sv1_{t-1} + v_3$$

$$sv4_t = \gamma_4 + \delta_4 sv1_{t-1} + v_4$$

Nótese que en las ecuaciones de estado, se permite que todos los componentes no observados dependan de sv1, convirtiendo a este componente en el factor común de todas las variables observadas que en este caso son los retornos de los portafolios, con esta especificación también permitimos que cada uno de las variables observadas dependa de forma diferente del factor común a través de las variables α y β , asumimos que los componentes no observables siguen un proceso AR(1).

También permitimos que la relación entre los componentes observables y los no observables esté sujeto a una perturbación estocástica a través de las variables u y v , donde asumimos que $cov(u'u, v'v) \neq 0$ es decir, permitimos una correlación entre las variables de estado y las variables de señal, ya que todas las variables de estado son combinaciones lineales de si mismas, será necesario hacer este supuesto.

De esta manera podemos resumir el modelo en dos ecuaciones matriciales.

$$y_t = \alpha_t + \beta_t s_t \tag{1}$$

$$s_{t+1} = \Gamma_t + \Delta_t s_t + \epsilon_t \tag{2}$$

Donde $\epsilon_t = u_t + v_t$ para permitir correlación entre los términos de error de las ecuaciones de estado y las ecuaciones de señal. Además restringimos un poco el modelo debido a la capacidad de computo haciendo que $\Gamma = 0_{n \times n}$ sin grandes cambios en los coeficientes.

Cuadro 46: Resultados filtro de Kalman, modelo sspace

	Coefficient	Std. Error	z-Statistic	Prob.
δ_1	0.706129	0.026824	26.32480	0.0000
δ_2	1.335191	20.04004	0.066626	0.9469
δ_3	2.737860	37.73229	0.072560	0.9422
δ_4	3.449793	52.91170	0.065199	0.9480
ϵ_1	1.260428	18.61196	0.067721	0.9460
ϵ_2	2.826096	27.33166	0.103400	0.9176
ϵ_3	4.705715	27.68324	0.169984	0.8650
ϵ_4	5.308685	32.53337	0.163177	0.8704
β_1	1.029003	9.575870	0.107458	0.9144
β_2	1.031614	14.09784	0.073175	0.9417
β_3	0.967344	13.38958	0.072246	0.9424
β_4	1.302104	21.18090	0.061475	0.9510
α_1	0.577393	0.248861	2.320143	0.0203
α_2	0.827483	0.369953	2.236726	0.0253
α_3	1.554421	0.748035	2.078005	0.0377
α_4	2.692297	1.293975	2.080640	0.0375
	Final State	Root MSE	z-Statistic	Prob.
SV1	-2.307270	4.805792	-0.480102	0.6312
SV2	-1.928916	2.883406	-0.668971	0.5035
SV3	-2.386134	7.227279	-0.330157	0.7413
SV4	-1.067494	5.008261	-0.213147	0.8312
Log likelihood	-9008.208	Akaike info criterion		26.09309
Parameters	20	Schwarz criterion		26.22429
Diffuse priors	0	Hannan-Quinn criter.		26.14383

El cuadro 46 muestra los resultados de la estimación del modelo state-space, para los coeficientes buscados y para los componentes no observados definidos como rezagos de sv1 por el algoritmo de Kalman, nuestro componente común producto del algoritmo de Kalman será la serie sv1 que asumimos sigue un proceso AR(1).

El algoritmo de Kalman busca la distribución de la media y la varianza condicional a la matriz de información disponible y cada periodo diferente, dadas estas distribuciones podemos calcular la predicción del siguiente periodos (one-step ahead prediction), Kalman actualiza secuencialmente esta predicción y su varianza dada nueva información, por lo que el factor común de los retornos podría entenderse como el proceso intrínseco de los movimientos de los retornos descontando los efectos temporales y por ende la volatilidad propia de tomar los retornos en diferentes cortes temporales.

La teoría que sugiere que los retornos de los bonos están compuestos por una parte de un bono libre de riesgo y otra parte adicional se conoce como la teoría de segmentación del mercado de bonos. Esta teoría sugiere que los inversionistas tienen preferencias y demandas diferentes en términos de riesgo y horizonte temporal, lo que lleva a una segmentación del mercado de bonos y a la existencia de diferentes tasas de interés para bonos con características distintas.

la teoría de segmentación del mercado de bonos sugiere que los retornos de los bonos están compuestos por una parte de un bono libre de riesgo y otra parte adicional. Esta teoría sugiere que los inversionistas tienen preferencias y demandas diferentes en términos de riesgo y horizonte temporal, lo que lleva a una segmentación del mercado de bonos y a la existencia de diferentes tasas de interés para bonos con características distintas.

Si consideramos esto podríamos descomponer las diferentes temporalidades de los rendimientos en dos componentes principales:

Componente de bono libre de riesgo que representa el rendimiento que se espera de un bono que no tiene riesgo de incumplimiento. Este componente está asociado a la tasa de interés libre de riesgo, que generalmente se toma como la tasa de interés de los bonos del gobierno considerados libres de riesgo, lo que en nuestro caso vendría a estar representado por el factor común sv1.

El otro componente puede ser considerado una prima de riesgo que representa una compensación adicional que los inversionistas exigen por asumir el riesgo asociado a un bono en particular. Este componente está influenciado por diversos factores, como la calificación crediticia del emisor, la liquidez del bono, las condiciones económicas y financieras, y las expectativas de inflación, por lo que al considerar un factor común de los rendimientos con diferente temporalidad podríamos estar descontando estos efectos adicionales.

Figura 11: state-space Eviews specification

```
@signal ex3mhold12 = c(13) + c(9)*sv1
@signal ex3mhold24 = c(14) + c(10)*sv2
@signal ex3mhold60 = c(15) + c(11)*sv3
@signal ex3mhold120 = c(16) + c(12)*sv4

@state sv1 = c(1)*sv1(-1) + [ename = e1]
@state sv2 = c(2)*sv1(-1) + [ename = e2]
@state sv3 = c(3)*sv1(-1) + [ename = e3]
@state sv4 = c(4)*sv1(-1) + [ename = e4]

@evar var(e1) = exp(c(5))
@evar var(e2) = exp(c(6))
@evar var(e3) = exp(c(7))
@evar var(e4) = exp(c(8))
```

Finalmente la figura 11 muestra la especificación del modelo state-space utilizada en Eviews.

- b) Add the slope to the measurement equation of your previous specification in (a). Compare the predicted states of both specifications.

Solución:

Para hallar una serie para la pendiente, repetimos el modelo manteniendo constante el coeficiente de la pendiente, lo que nos dará un equivalente a una pendiente común de las series y lo estimamos de igual manera por Kalman.

Luego se calcula el mismo modelo en a) considerando los coeficientes para esta pendiente común.

Figura 12: Predicted states from the a) model


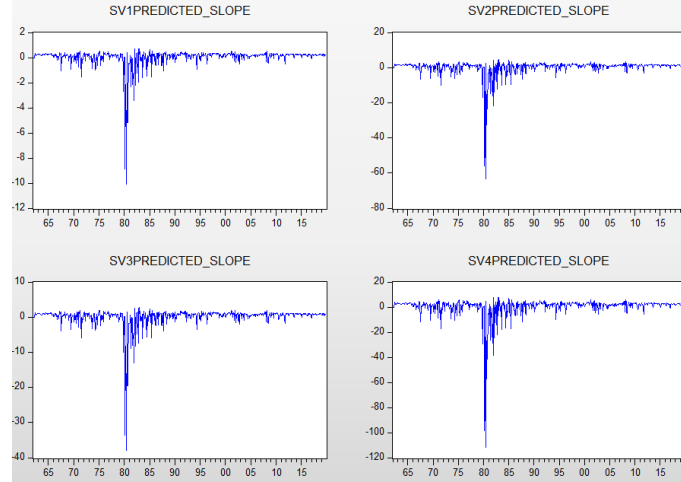


Figura 13: Predicted states using the slope



Las figuras 12 y 13 muestran las predicciones para las ecuaciones de estado considerando el modelo en el primer literal y utilizando la pendiente respectivamente, nótese que al utilizar la pendiente para predecir los valores de estado de las variables, la volatilidad del proceso que genera la serie parece ser menor si bien mucho más sensible a outliers, podría ser que la estimación del factor común como proxy del rendimiento del bono libre de riesgo corregido a través de los términos de la pendiente descuenta en gran parte la volatilidad que factores exógenos si bien parece ser muy sensible a outliers de volatilidad, es evidencia a que existe un proceso dentro de la serie que está asociado a un menor volatilidad.

6. Use the Eviews data file named Money.wf1

The data file contains the variables m , y , i and p representing M1, industrial production, a 3 months interest rate and prices, respectively. Consider the following equation:

$$\log(m_t) - \log(p_t) = \alpha_0 + \alpha_1 i_t + \alpha_2 \log(y_t) + \epsilon_t$$

- a) Estimate for the period 1962m1-2019m11 the above equation using Markov Chain Monte Carlo techniques.

Solución: Para calcular la ecuación a través de Montecarlo Markov chain es necesario primero calcular la variable dependiente y el logaritmo de la variable y , una vez con esto podemos estimar.

Cuadro 47: Posterior Statistics 1962-2019

Variable	Posterior Mean	Posterior SD	95 % Lower	95 % Upper
α_0	0.320427	0.081701	0.158947	0.479355
i_t	-0.036969	0.002284	-0.041517	-0.032434
$\log(y_t)$	0.421342	0.018246	0.385584	0.457375
Sigma Squared	0.029195	0.001567	0.026311	0.032376

El cuadro 47 muestra los estadísticos posteriores del modelo planteado por MCMC. La distribución posterior representa las creencias actualizadas sobre los parámetros después de incorporar la información de los datos y las creencias previas. Hay que considerar que el método MCMC nos permiten simular a partir de la distribución posterior y estimar los parámetros de interés.

Si vemos los resultados de la estimación bayesiana utilizando técnicas de MCMC para el periodo 1962-2019 que se corresponde con todo el tamaño de la muestra el valor medio de α_0 posterior es 0.319065, lo cual indica que en promedio se espera que esta variable tenga un efecto positivo en la respuesta.

Si vemos los resultados para la variable i_t el valor medio posterior indica que se espera que la tasa de interés tenga un efecto negativo sobre la diferencia de los logaritmos del multiplicador del dinero y los precios durante este periodo, si vemos el desvío estándar podríamos decir que esta estimación es más precisa y se espera que no cambie mucho, también se espera que los cambios en el producto tengan un efecto positivo.

Durante todo el periodo se espera considerando las distribuciones iniciales de las series que la tasa de interés afecta de forma negativa al spread de los cambios en los precios, se puede decir también que con la información revelada durante este periodo los cambios en el producto tienen un impacto positivo sobre el spread de los cambios en los precios.

- b) Compare the dispersion of α_1 and of α_2 for the sub-samples 1962m1-1979m1, 1979m1-1982m12 and 1983m1-2019m11

Solución:

Cuadro 48: Posterior Statistics 1962-1979

Variable	Posterior Mean	Posterior SD	95 % Lower	95 % Upper
α_0	1.067758	0.121481	0.831278	1.304370
i_t	-0.005714	0.003995	-0.013613	0.002078
$\log(y_t)$	0.172377	0.037453	0.098704	0.245600
σ^2	0.005020	0.000485	0.004150	0.006072

Cuadro 49: Posterior Statistics 1979-1982

Variable	Posterior Mean	Posterior SD	95 % Lower	95 % Upper
α_0	-2.825861	2.785933	-8.291948	2.750858
i_t	-0.011387	0.008594	-0.028340	0.005623
$\log(y_t)$	1.148247	0.715894	-0.284317	2.552176
σ^2	0.017123	0.003544	0.011544	0.025302

Cuadro 50: Posterior Statistics 1983-2019

Variable	Posterior Mean	Posterior SD	95 % Lower	95 % Upper
α_0	0.414937	0.315744	-0.203885	1.036475
i_t	-0.045416	0.005511	-0.056157	-0.034704
$\log(y_t)$	0.405865	0.067815	0.272438	0.538288
σ^2	0.043196	0.002900	0.037880	0.049322

Los cuadros 48, 49 y 50 muestran los estadísticos que resumen la distribución posterior del experimento MCMC, vemos que en las tres submuestras encontramos diferencias significativas en los resultados de la estimación bayesiana, hay que considerar que este tipo de estimación actualiza las estimaciones a medida que se revela nueva información por lo que es de esperar que si las series cambian en el tiempo o siguen algún tipo de tendencia, los resultados cambien debido a que la nueva información puede llevar a esperar diferentes efectos.

Podemos ver que el valor esperado de la constante disminuye desde la submuestra 1 a la 2 y vuelve a subir para la submuestra 3, el efecto esperado de la tasa de interés sobre el spread de los precios es siempre negativo lo que además se corresponde con la teoría, a lo largo de las submuestras el coeficiente esperado de la tasa de interés cambia aunque muy poco, esto quiere decir que el efecto de la tasa de interés sobre el spread de los precios es en cierto sentido robusto a la revelación de nueva información, sin embargo podemos ver que en la submuestra 1 y 2 los intervalos de confianza donde vive la estimación incluyen al cero, mientras que en la submuestra 3 no, esto podría estar asociado con algún cambio de política que lleva a modificar las expectativas sobre la tasa de interés.

El impacto esperado de cambios en el producto cambia bastante entre submuestras, vemos que en la submuestra 2, el cambio en el producto tiene un impacto positivo mucho más grande sobre el spread de los precios que en las otras submuestras, esto se puede deber al ciclo económico, y también señala que las expectativas durante el periodo 1979-1982 eran más altas, a medida que se va actualizando la información, se espera

un impacto menor de el cambio en el producto sobre el spread de los precios, hay que considerar que la matriz de información para cada submuestra no se refiere a información que puedan tener los consumidores sino que se refiere al proceso de estimación bayesiano. En conclusión la submuestra 2, durante el periodo 1979-1982 es el que tiene mucha mayor volatilidad para todas las variables y también tiene inmpactos mayores, esto puede estar asociado a la situación de formación de tendencia alcista como se puede apreciar en las figuras 14, 15 y 16 que permite reflejar una relación entre las variables que no se puede alcanzar solamente con regresiones.

Figura 14: state-space Eviews specification




Figura 15: state-space Eviews specification





Figura 16: state-space Eviews specification



c) How do the results that use a non-informative prior compare with those using OLS?

Solución:

Las técnicas de Markov Chain Monte Carlo (MCMC) permiten estimar modelos complejos que involucran espacios de parámetros de alta dimensión, relaciones no lineales y variables latentes como la definida en este caso que no podría ser estimada a traes de OLS sin violar los supuestos de OLS, intentar el procedimiento MCMC con una distribución a priori no informativo no cambia mucho los resultados de las estimaciones debido a que el atécnica MCMC, actualiza la distribución a priori de forma dinámica, por lo que empezar con una distribución a priori no informativa no cambiaria demasiado los reultados, Los métodos de MCMC son particularmente útiles cuando no son factibles o eficientes las soluciones analíticas o las técnicas de estimación estándar.

Ahora si se utiliza OLS como método en un experimento de montecarlo de igual manera la estimación MCMC tendrá ventajas, MCMC se basan en el concepto de una cadena de Markov, que es una secuencia de variables aleatorias donde el valor en cada paso depende solo del valor anterior. En MCMC, se construye la cadena de Markov para explorar el espacio de parámetros. Una vez que la cadena de Markov ha convergido, se puede realizar la inferencia posterior. Esto implica resumir los valores de los parámetros muestreados para obtener estimaciones puntuales y construir intervalos de credibilidad o distribuciones posteriores para cuantificar la incertidumbre.

El uso de una cadena de Markov implica que aunque se utiliza una distribución a priori no informativa en MCMC la estimación de incertidumbre de MCMC será más robusta de la incertidumbre en comparación con OLS. MCMC produce distribuciones posteriores para los parámetros del modelo, lo que permite la cuantificación de la incertidumbre mediante medidas como las desviaciones estándar posteriores o los intervalos de credibilidad. En contraste, OLS asume homocedasticidad y errores distribuidos normalmente, proporcionando errores estándar pero no una distribución posterior completa.

MCMC con una a priori no informativa puede manejar valores atípicos y observaciones influyentes de manera más efectiva en comparación con OLS. Al permitir una estimación de parámetros más flexible, MCMC es menos sensible a observaciones extremas y puede capturar una variedad más amplia de patrones de datos. OLS, por otro lado, puede verse fuertemente influenciado por valores atípicos, lo que conduce a estimaciones de parámetros sesgadas.

MCMC con una priori no informativa no incorpora ningún conocimiento previo o supuestos sobre los parámetros del modelo, permitiendo que los datos impulsen el proceso de estimación. OLS al ser un procedimiento que proviene de la estadística frecuentista no tiene en cuenta explícitamente la información previa y se basa únicamente en los datos observados sobre los cuales hace suposiciones. Si hay un conocimiento previo sustancial disponible, el uso de distribuciones a priori informativas en el análisis de MCMC puede mejorar la estimación al incorporar esa información.

Además los modelos MCMC pueden manejar modelos complejos con un gran número de parámetros de manera más efectiva que OLS. A medida que aumenta la complejidad del modelo, OLS puede encontrar problemas como la multicolinealidad o el sobreajuste, lo que lleva a estimaciones de parámetros inestables o poco confiables. MCMC, con su capacidad para explorar el espacio de parámetros y capturar relaciones complejas, puede proporcionar resultados más sólidos en estos casos.

Se esperaría en general que los resultados obtenidos mediante MCMC con una priori no informativa sean más confiables, flexibles y robustos en comparación con OLS. Sin embargo, es esencial evaluar cuidadosamente el contexto específico y los requisitos del análisis para determinar el enfoque más adecuado para una pregunta de investigación determinada y especialmente la complejidad del modelo pues MCMC podría llegar a requerir mucha capacidad de computo.